Министерство науки и высшего образования Российской Федерации ФГАОУ ВО «Южно-Уральский государственный университет (НИУ)» Институт естественных и точных наук

Факультет математики, механики и компьютерных технологий Кафедра прикладной математики и программирования Направление подготовки: 01.03.02 «Прикладная математика и информатика»

СВЕРХРАЗРЕШЕНИЕ ИЗОБРАЖЕНИЙ С ПОМОЩЬЮ ГЕНЕРАТИВНО-СОСТЯЗАТЕЛЬНОЙ НЕЙРОННОЙ СЕТИ

Руководитель:

доцент кафедры ПМиП, к.ф.-м.н.

Т.В. Карпета

Автор работы:

студент группы ЕТ-412

М.А. Васюк

Челябинск, 2020

🤛 ЦЕЛЬ И ЗАДАЧИ

Целью данной работы является разработка искусственной нейронной сети для повышения разрешения изображений без потери качества.

Для достижения данной цели необходимо решить следующие задачи:

- •изучение и исследование существующих методов для решения задачи повышения разрешения изображения без потери качества;
 - сбор и подготовка данных для обучения нейронной сети;
 - •разработка математической модели искусственной нейронной сети;
 - •обучение сети и оценка качества модели на экспериментальных данных.

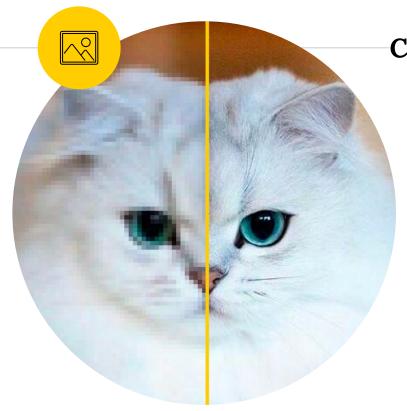


Рисунок 1 – Повышение разрешения изображения

СВЕРХРАЗРЕШЕНИЕ ИЗОБРАЖЕНИЙ

X – множество изображений низкого разрешения.

Y – множество изображений высокого разрешения.

Необходимо восстановить целевую функцию $f^*: X \to Y$.



СУЩЕСТВУЮЩИЕ МЕТОДЫ







СУЩЕСТВУЮЩИЕ РЕШЕНИЯ

- Bigjpg.com;
- Let's Enhance;
- Pichance.com;
- waifu2x.





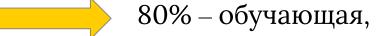
Рисунок 2 – Пример работы сервиса Let's Enhance



ИСХОДНЫЕ ДАННЫЕ

- DIV2K;
- Flickr1024;
- InStereo2K;
- ImageNet.

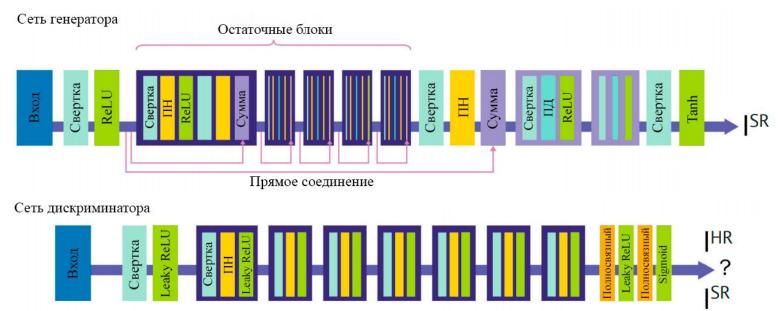
10 000 пар изображений:



20% – тестовая.



АРХИТЕКТУРА СЕТИ SRGAN



ПН – пакетная нормализация, ПД – слой повышения дискретизации, ReLU, Leaky ReLU, Tanh, Sigmoid – функции потерь, HR – изображение высокого разрешения, SR – сгенерированное изображение (выход сети)

Рисунок 3 – Архитектура сети



ФУНКЦИИ АКТИВАЦИИ

Leaky ReLU:

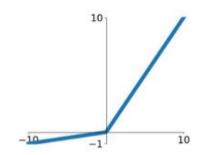


Рисунок 4 – Функция активации Leaky ReLU

Sigmoid:

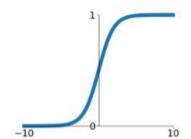


Рисунок 5 – Функция активации Sigmoid

$$f(y) = \begin{cases} 0.01y, y < 0, \\ y, y > 0. \end{cases}$$
 (1)

$$f(y) = \frac{2}{1 + e^{-2y}} - 1.$$
 (2)

ФУНКЦИИ ПОТЕРЬ

$$l_{CL} = \frac{1}{mn} \sum_{i=1}^{m} \sum_{j=1}^{n} (I_{i,j}^{HR} - G(I^{LR})_{i,j})^{2}, \qquad (3) \qquad l_{AL} = -\sum_{i=1}^{N} \ln D(G(I_{i}^{LR})), \qquad (4)$$

т – ширина изображения,

n – высота изображения,

і, ј – координаты пикселя,

 I^{HR} — эталонное изображение высокого разрешения,

 I^{LR} — изображение низкого разрешения,

 $G(I^{LR})$ — сгенерированное сетью изображение высокого разрешения,

 $D(G(I^{LR}))$ — выход дискриминатора для сгенерированного изображения,

 N_{-} — количество изображений в пакете.



ФУНКЦИИ ПОТЕРЬ

$$l = l_{CL} + 0.001 \cdot l_{AL}, \tag{5}$$

 l_{CL} — функция потерь контента,

 l_{AL} – состязательная функция потерь.

$$MSE = \frac{1}{N} \sum_{i=1}^{N} (p_i - y_i)^2,$$
 (6)

N – количество изображений в пакете,

 p_{i} — реальный выход дискриминатора для i-го изображения,

*у*_і – верный (желаемый) выход дискриминатора.



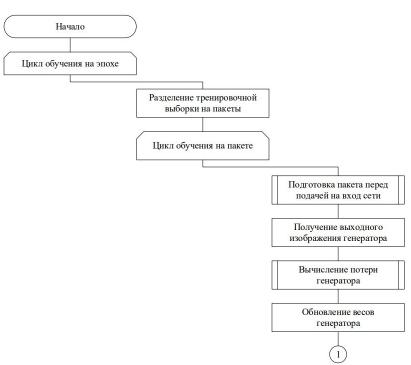
СХЕМЫ АЛГОРИТМОВ



Рисунок 6 – Алгоритм работы программы



СХЕМЫ АЛГОРИТМОВ



Получение выхода дискриминатора Вычисление потери дискриминатора Обновление весов дискриминатора Конец прохода всех пакетов выборки через сеть Сохранение весов модели Достигнуто необходимое количество эпох Конец

Рисунок 7 – Алгоритм обучения сети (1)

Рисунок 8 – Алгоритм обучения сети (2)



РЕЗУЛЬТАТЫ ОБУЧЕНИЯ

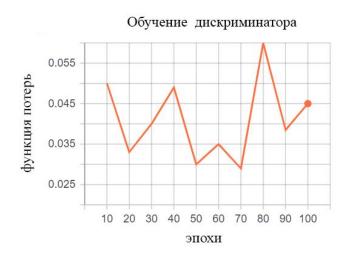


Рисунок 9 – График обучения дискриминатора



Рисунок 10 – График обучения генератора



МЕТРИКИ КАЧЕСТВА

$$PSNR = 20 \lg \left(\frac{255}{\sqrt{\sigma}}\right),\tag{7}$$

 σ — среднеквадратичное отклонение для сравниваемого (x) и эталонного (y) изображений:

$$\sigma = \frac{1}{3mn} \sum_{i=0}^{m-1} \sum_{l=0}^{n-1} \sum_{l=0}^{2} |x_l(i,j) - y_l(i,j)|^2,$$
(8)

m — ширина изображения,

n – высота изображения,

l – номер канала изображения,

i, j – координаты пикселя.



МЕТРИКИ КАЧЕСТВА

$$SSIM = \frac{(2\mu_x \mu_y + K)(2\sigma_{xy} + K)}{(\mu_x^2 + \mu_y^2 + K)(\sigma_x^2 + \sigma_y^2 + K)},\tag{9}$$

- x сравниваемое изображение,
- у эталонное изображение,
- μ_x среднее арифметическое сравниваемого изображения,
- μ_{y} среднее арифметическое эталонного изображения,
- σ_x^2 дисперсия для сравниваемого изображения,
- $\sigma_{\rm V}^2$ дисперсия для эталонного изображения,
- σ_{xy} корреляционный момент изображений,
- _К выравнивающий коэффициент (равен 0.01).



ПРИМЕРЫ РАБОТЫ СЕТИ

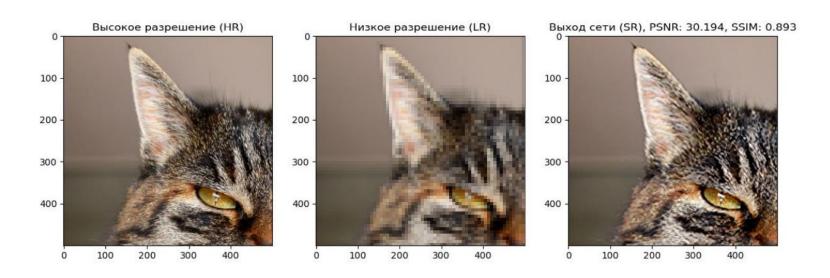


Рисунок 11 – Пример работы сети



ПРИМЕРЫ РАБОТЫ СЕТИ



Рисунок 12 – Пример работы сети



СРАВНИТЕЛЬНЫЙ АНАЛИЗ

Таблица 1 – Сравнение с интерполяционными методами

	Ближайший сосед	Билинейная интерполяция	Бикубическая интерполяция	Интерполяция Ланцоша	GAN
PSNR	29.40	29.84	30.64	30.51	32.05
SSIM	0.79	0.84	0.87	0.88	0.91



- •в результате работы, было проведено исследование существующих методов решения задачи сверхразрешения;
- •для обучения нейронной сети был собран и подготовлен набор данных изображений;
- •была построена математическая модель нейронной сети, а также описаны методы ее обучения;
- •данная сеть была реализована, обучена и протестирована на тестовых данных;
- опроведен сравнительный анализ эффективности методов повышения разрешения изображений.

Полученное решение имеет практическое применение в проектах компании ООО «Цифровая собственность».

СПАСИБО ЗА ВНИМАНИЕ!

🔗 ФОРМУЛЫ

$$\mu_{x} = \frac{1}{M} \sum_{i=1}^{M} x_{i}; \qquad (2.20)$$

где σ_x^2 – дисперсия для оригинального изображения (σ_y^2 – для оцениваемого) размером M пикселей:

$$\sigma_x^2 = \frac{1}{M} \sum_{i=1}^{M} (x_i - \mu_x)^2; \tag{2.21}$$

где σ_{xy} – корреляционный момент участков сравниваемых изображений:

$$\sigma_{xy} = \frac{1}{M} \sum_{i=1}^{M} (x_i - \mu_x) (y_i - \mu_y); \tag{2.22}$$



Алгоритм работы:

- 1) инициализация начальных моментов: $M_0 = 0$, $R_0 = 0$;
- 2) для каждого веса W_t , t = 1, ..., T выполнить:
 - оценку первого момента:

$$M_t = \beta_1 M_{t-1} + (1 - \beta_1) \nabla L_t(W_{t-1}); \tag{2.12}$$

- оценку второго момента:

$$R_t = \beta_2 R_{t-1} + (1 - \beta_2) \nabla L_t(W_{t-1})^2; \tag{2.13}$$

- коррекцию смещения первого момента:

$$\widehat{M_t} = \frac{M_t}{(1 - \beta_1)^t};\tag{2.14}$$

- коррекцию смещения второго момента:

$$\widehat{R_t} = \frac{R_t}{(1 - \beta_2)^t};\tag{2.15}$$

- обновление:

$$W_t = W_{t-1} - \alpha \frac{\widehat{M_t}}{\sqrt{\widehat{R_t} + \varepsilon}}.$$
 (2.16)

3) вернуть веса W_T .

🔗 ФОРМУЛЫ

Шаг 1. Инициализация синаптических весов и смещений. В циклах по $k=1,2,...,K; i=1,2,...,H_k; j=0,1,2,...,H_{k-1}$ генератор случайных чисел присваивает синаптическим весам и смещениям $w_{ij}^{(k)}$ малые величины, например, из диапазона от -1 до 1.

Шаг 2. Открытие цикла по q=1,2,...,Q. Представление из обучающего множества примеров очередного входного вектора $X_q=(x_1,x_2,...,x_N)_q$ и соответствующего ему желаемого выходного вектора $D_q=(d_1,d_2,...,d_M)_q$, где q – номер примера в обучающем множестве.

炒 ФОРМУЛЫ

Шаг 3. Прямой проход. В циклах по $k=1,2,...,K; i=1,2,...,H_k$ вычисляются выходные сигналы i-го нейрона в k-ом слое:

$$y_i^{(k)} = f\left(\sum_{j=0}^{H_{k-1}} w_{ij}^{(k)} y_j^{(k-1)}\right), \tag{2.7}$$

где $y_j^{(0)} = x_j; x_0 = 1; y_0^{(k-1)} = 1; y_i = y_i^{(K)}$ – выходные сигналы персептрона.

Шаг 4. Обратный проход. В циклах по $k=K,K-1,\dots,1; i=1,2,\dots,H_k;$ $j=0,1,2,\dots,H_{k-1}$ вычисляются синаптические веса на новой эпохе:

$$w_{ij}^{(k)}(t+1) = w_{ij}^{(k)}(t) + \Delta w_{ij}^{(k)}, \tag{2.8}$$

$$\Delta w_{ij}^{(k)} = \eta \delta_i^{(k)} y_j^{(k+1)}. \tag{2.9}$$

Для нейронов выходного слоя k = K:

$$\delta_i^{(K)} = y_i (1 - y_i) (d_i - y_i). \tag{2.10}$$

Для остальных скрытых слоев:

$$\delta_i^{(k)} = y_i^{(k)} \left(1 - y_i^{(k)} \right) \sum_{l=1}^{H_{k+1}} \delta_l^{(k+1)} w_{li}^{(k+1)}. \tag{2.11}$$

Шаг 5. Закрытие цикла по q.

Шаг 6. Повторение шагов 2–5 необходимое количество раз. Векторы обучающих примеров X_q и D_q на шаге 2 алгоритма обычно представляются последовательно от первого до последнего, т. е. q=1,2,...,Q, где Q – общее количество примеров.